

KV cache 최적화 기술 다관점 평가 — KIVI(SW) · InfiniGen(HW) · 스마트폰 온디바이스 LLM

SUMMARY

KV cache 최적화 기술인 KIVI(소프트웨어)와 InfiniGen(하드웨어)을 스마트폰 온디바이스 LLM 도메인에서 기술 성숙도, 시장, 이해관계자, 도메인 적합성 관점으로 비교했다. 기술 성숙도에서는 KIVI가 TRL 4, InfiniGen이 TRL 3으로 평가되며 공개 정보 기반 추정임을 알 수 있다. 시장 관점에서 KIVI는 중간 수준의 채택과 생태계 연결 근거가 있으나, InfiniGen은 채택과 시장 연결 근거가 부족하다. 이해관계자 관점에서는 KIVI가 단순한 2비트 압축 기술로 평가받는 반면, InfiniGen은 데이터 전송 병목과 정확도 저하 가능성으로 제한적 평가를 받는다. 도메인 적합성에서는 KIVI가 스마트폰 온디바이스 환경에 적합한 반면, InfiniGen은 CPU 메모리 오프로딩과 PCIe 대역폭 전제를 요구해 조건부 적합으로 판단된다. 가장 큰 엇갈림은 두 기술이 요구하는 하드웨어 및 메모리 계층 전제 조건과 이로 인한 도메인 적합성 평가 차이에서 나타난다[논문 2402.02750 p.2, 2406.19707 p.4, p.6]. 본 보고서는 공개 정보 기반 추정에 의존하며, 판단 문장 중 약 5%가 [추론] 태그를 포함한다.

1. 분석 배경

KV cache는 대규모 언어 모델(LLM)에서 토큰별 약 0.5MB(7B, fp16, MHA 기준)의 메모리를 요구하며, 문맥 길이가 늘어날수록 용량이 선형적으로 증가한다. 이로 인해 초기의 연산 병목이 점차 메모리 병목으로 전환되는 현상이 나타난다. 이러한 특성은 특히 메모리 자원이 제한적인 환경에서 문제를 심화시킨다. KV cache 최적화 접근법은 크게 두 가지로 구분된다. 첫째는 소프트웨어적 방법으로, 압축이나 양자화 등을 통해 저장 데이터를 줄이는 방식이며, 둘째는 하드웨어적 방법으로, 메모리나 스토리지 계층을 확장하여 저장 공간을 넓히는 방식이다. 스마트폰 온디바이스 LLM은 메모리 확장이 불가능하고 배터리 제약과 재학습 불가 조건이 존재한다. 또한, 어시스턴트 응답 품질이 제품 품질과 직결되므로 압축 손실에 민감하다. 대표적인 시나리오로는 12GB RAM 환경에서 4bit 7B 모델을 사용하며, 8K 토큰 문맥을 처리할 때 fp16 KV cache가 약 4GB를 차지하는 경우가 있다. 이 도메인에서는 Recall, Latency, Memory 세 축을 동시에 최적화하기 어렵고, 특히 메모리 제약이 절대적이다. 따라서 본 보고서는 각 최적화 기법이 무엇을 포기했으며, 그 포기가 스마트폰 온디바이스 LLM 환경에서 감당 가능한지를 평가하는 데 초점을 맞춘다.

2. 기술 선정

선정 기준 (설계서 1.1)

- 온디바이스 적용 가능성 — 별도의 학습이나 전용 하드웨어 없이 기존 모델에 적용할 수 있는가

- **평가 자료 확보 가능성** — 오픈소스 구현·후속 연구·개발자 논의·제품 적용 사례가 충분한가
- **기술 성숙도** — TRL 기준 성숙 수준이 비교 가능한가, 공개 시점 차이로 불공정하지 않은가
- **RAG Corpus 적합성** — KV cache 가 논문의 주제인가, 2편 합쳐 200p 이내인가

선택 기술

- **SW · KIVI** — KIVI: A Tuning-Free Asymmetric 2bit Quantization for KV Cache (ICML 2024, PMLR 235, arXiv:2402.02750, 15p)
- 사후·무보정 2bit KV 양자화. 재학습·보정 데이터 없이 배포된 모델에 즉시 적용 가능, 피크 메모리 2.6x 감소. 정확도 trade-off 가 관점 대조 재료 (설계서 1.3)
- **HW · InfiniGen** — InfiniGen: Efficient Generative Inference of Large Language Models with Dynamic KV Cache Management (OSDI 2024, arXiv:2406.19707, 18p)
- 동적 KV 오프로딩·프리패치. 전용 HW 없이 메모리 계층을 쓰는 유일한 후보, 정확도 무손실 vs 전송·전력 비용 (설계서 1.4)

검토했으나 제외한 후보

- TurboQuant (SW) — 설계서 1.2 참고
- DeepSeek-V2 MLA (SW) — 아키텍처 재설계 — 배포된 모델에 사후 적용 불가
- ITME CXL (HW) — 전용 인터커넥트 필요 — 스마트폰에 없음
- PIM-CXL (HW) — 전용 HW 필요

3. 기술 개요

KIVI

KIVI는 긴 컨텍스트나 배치 추론 시 KV 캐시의 저장 및 로딩에서 발생하는 메모리와 속도 병목 현상을 완화하기 위해 KV 캐시를 2비트로 양자화하는 접근을 취한다. 이 기술은 key와 value 캐시를 그룹 단위로 양자화하고, 잔여 부분은 원래 정밀도로 유지하여 긴 시퀀스에서 메모리 오버헤드를 최소화한다. 또한, 디퀀타이즈와 행렬 곱셈을 융합하는 혼합 정밀도 행렬 곱셈(Q_MatMul)을 통해 효율성을 높인다. KIVI는 Llama, Mistral, Falcon 모델에서 평가되었으며, Llama-2-7B 모델에서 KV 캐시를 2비트로 압축해 2.6×의 피크 메모리 사용량 감소, 최대 4× 더 큰 배치 크기 지원, 2.35×~3.47× 처리량 향상을 보였다[p.1][p.2][p.3][p.5][p.6][p.8][p.9][p.12].

한계로는 2비트 KIVI가 multi-query attention 환경에서 정확도 하락을 보일 수 있어, 4비트 KIVI가 필요한 경우가 있다는 점이 있다[p.6].

적용 시 재학습이나 보정 데이터, 전용 하드웨어, 사전 계산, 하이퍼파라미터 조정에 대한 별도 요구 없이 GPU에서 CUDA 및 Triton을 활용한 하드웨어 친화적 구현이 가능하며, Llama2-7B, 13B, Falcon-7B, Mistral-7B 등 다양한 모델에 적용되었다[p.6][p.8].

KIVI는 메모리 사용량과 처리량을 개선하는 대신 일부 상황에서 정확도(Recall)를 희생할 수 있는 특성을 가진다[추론].

InfiniGen

InfiniGen은 긴 텍스트 생성에 최적화된 KV 캐시 관리 프레임워크로, 오프로딩 기반 LLM 추론 시스템과 협력하여 CPU 메모리에 있는 KV 캐시 중 중요한 토큰만을 추측적으로 미리 GPU로 가져오는 방식을 사용한다. 이를 위해 이전 레이어의 attention 입력과 쿼리 및 키 가중치를 활용해 필수 KV 캐시 항목을 동적으로 선별하고, 미리 가져올 항목 수를 조절하며, 자주 사용되지 않는 항목은 동적으로 제거한다. 이로써 KV 캐시 전송 오버헤드를 줄이고 추론 지연 시간을 단축한다[p.1][p.2][p.4][p.6][p.14].

평가에서는 OPT 6.7B, 13B, 30B 및 Llama-2 7B, 13B 모델을 사용했으며, FlexGen 대비 데이터 전송량 감소로 추론 속도가 크게 향상되었고, Ideal 대비 1.52× 느린 반면 다른 방법들은 3.90×~18.55× 느린 결과를 보였다[p.9][p.13][p.14].

한계로는 KV 캐시 크기가 10%보다 작을 때 정확도가 떨어지는 경우가 있으며, 이는 양자화나 영구적인 KV 캐시 제거 때문이라고 언급된다. 또한 CPU에서 GPU로 KV 캐시를 전송하는 과정이 새로운 성능 병목이 될 수 있다[p.1][p.10].

재학습, 보정 데이터, 전용 하드웨어, 사전 계산, 하이퍼파라미터 조정 없이 기존 OPT 및 Llama-2 모델에 적용되었다[p.9].

InfiniGen은 추론 지연 시간을 줄이는 데 집중하면서도 정확도를 유지하는 대신, KV 캐시 전송량과 메모리 관리에 중점을 둔 접근으로 메모리와 지연 시간 간 균형을 추구한다[추론].

4. 관점별 평가

4.1 기술 성숙도 (TRL — 공개 정보 기반 추정, 기준 시점 명시)

- KIVI — TRL 4 (기준 시점: 2024 공개 자료 기준)
 - [논문 2402.02750] 공개 논문 및 GitHub 구현체 확인
 - [웹 <https://github.com/jy-yuan/KIVI>] 공개 코드 및 하드웨어 친화적 구현체 존재
- InfiniGen — TRL 3 (기준 시점: 2024 공개 자료 기준)
 - [논문 2406.19707] 공개 논문 및 GitHub 구현체 확인
 - 재학습·보정 데이터 및 벤더 제품 적용 발표 미확인 [추론]

TRL 4~6 구간은 수율·성능 수치가 비공개라 정보 공백이 크고, 발표 시점과 채택 사이에 시차가 있다. 위 등급은 공개 정보 기반 추정이다.

4.2 시장

- KIVI — 등급: 채택: 중 / 시장 연결: 중 / 생태계: 중
 - 근거: 채택: KIVI는 Llama, Falcon, Mistral 등 인기 모델 패밀리에 적용되어 평가되었으며, HuggingFace Transformers의 KV Cache 양자화에도 영감을 주었다. [웹 <https://github.com/jy-yuan/KIVI>] 시장 연결: KIVI는 KV 캐시 메모리 절감과 처리량 향상을 통해 온디바이스 LLM 추론 효율화를 목표로 하며, 관련 시장에서 메모리 절감 수요에 부합한다. [웹 <https://arxiv.org/html/2402.02750v2>] 생태계: KIVI는 CUDA 및 Triton을 이용한 하드웨어 친화적 구현체가 존재하며, GitHub에 코드가 공개되어 있다. [웹 <https://github.com/jy-yuan/KIVI>]

○ 긍정:

- KIVI는 Llama-2-7B에서 KV 캐시를 2bit로 압축하여 2.6배 메모리 사용량 감소와 최대 4배 배치 크기 지원, 2.35~3.47배 처리량 향상을 달성했다. [웹 <https://arxiv.org/html/2402.02750v2>]
- KIVI는 미세 조정 없이 하드웨어 친화적인 2bit KV 캐시 양자화 알고리즘으로, Llama, Falcon, Mistral 모델에서 평가되었다. [웹 <https://arxiv.org/html/2402.02750v2>]
- KIVI는 CUDA와 Triton을 이용해 디퀀타이즈와 행렬 곱셈을 융합하는 효율적인 구현체를 제공한다. [웹 <https://arxiv.org/html/2402.02750v2>]

○ 부정:

- 2bit KIVI는 multi-query attention과 KV cache에 하나의 헤드만 사용하는 경우 큰 정확도 하락이 발생할 수 있어 4bit KIVI가 필요할 수 있다. [웹 <https://arxiv.org/html/2402.02750v2>]
- KIVI는 단일 NVIDIA A100 GPU (80GB) 환경에서 평가되어, 다양한 하드웨어 환경에서의 성능 검증은 제한적이다. [웹 <https://arxiv.org/html/2402.02750v2>]

○ confidence: 0.8

• InfiniGen — 등급: 채택: 근거 없음 / 시장 연결: 근거 없음 / 생태계: 상

- 근거: 채택: 유효한 근거 없음 [추론] 시장 연결: 유효한 근거 없음 [추론] 생태계: InfiniGen은 OSDI 2024에서 발표되었고, GitHub에 구현체가 공개되어 있으며, 여러 LLM 모델에서 평가되었다. [웹 <https://github.com/snu-comparch/InfiniGen>] 검색 결과로 확인되지 않은 근거 제외 [추론]

○ 긍정:

- 근거 없음

○ 부정:

- CPU 메모리에서 GPU로 KV 캐시를 전송하는 과정이 LLM 추론에서 새로운 성능 병목 현상이 될 수 있다. [웹 <https://arxiv.org/abs/2406.19707>]

○ confidence: 0.3

4.3 이해관계자 (찬 · 반)

• KIVI — 등급: 경쟁 기술 진영: 중립 / 도입 기업·개발자: 우호 / 투자·미디어: 근거 없음

- 근거: 경쟁 기술 진영: TurboQuant와 같은 경쟁 기술은 KIVI와 달리 3~4비트 범위에서 낮은 왜곡과 장기 컨텍스트 품질 유지에 중점을 둔다. TurboQuant는 더 복잡한 수학적 기법으로 왜곡을 줄이는 반면, KIVI는 2비트 캐시 압축에 더 단순하고 직접적으로 최적화되어 있다. 따라서 두 기술은 정확도, 복잡성, 압축률 측면에서 서로 다른 최적점을 추구한다. [웹 <https://turbo-quant.com/turboquant-vs-kivi>] 도입 기업·개발자: KIVI는 미세 조정 없이 바로 적용 가능한 2비트 KV 캐시 양자화 알고리즘으로, Llama, Mistral, Falcon 등 여러 인기 모델에서 평가되었으며, 최대 2.6배 메모리 사용량 감소와 2.35~3.47배 처리량 향상을 달성했다. 하드웨어 친화적인

CUDA 및 Triton 구현을 제공하며, 별도의 재학습이나 보정 데이터가 필요하지 않아 도입 장벽이 낮다. [웹 <https://arxiv.org/html/2402.02750v2>] 투자·미디어: 직접적인 투자자나 미디어의 반응이나 사업성 평가 자료가 제공되지 않아 판단 근거가 부족하다. [추론]

○ 긍정:

- KIVI는 Llama-2-7B 모델에서 KV 캐시를 2비트로 압축하여 2.6배의 피크 메모리 사용량 감소를 달성하고, 최대 4배 더 큰 배치 크기와 2.35~3.47배 처리량 향상을 보였다. [웹 <https://arxiv.org/html/2402.02750v2>]
- KIVI는 키 캐시는 채널 단위로, 값 캐시는 토큰 단위로 비대칭적으로 양자화하여 2비트 극한 압축에도 불구하고 정확도 손실을 최소화한다. [웹 <https://liner.com/review/kivi-tuningfree-asymmetric-2bit-quantization-for-kv-cache>]
- KIVI는 미세 조정 없이 바로 적용 가능한 플러그 앤 플레이 방식이며, CUDA와 Triton을 이용한 하드웨어 친화적 구현으로 실제 GPU 환경에서 효율적인 연산을 지원한다. [웹 <https://arxiv.org/html/2402.02750v2>]
- KIVI는 Llama, Falcon, Mistral 등 다양한 인기 모델에 적용되어 거의 동일한 품질을 유지하면서 메모리 사용량을 크게 줄이고 처리량을 향상시켰다. [웹 <https://medium.com/@michael.hannecke/google-turboquant-changes-the-economics-of-local-ai-inference-acce5839014d>]

○ 부정:

- KIVI 2비트 양자화는 경우에 따라 큰 정확도 하락을 보일 수 있으며, 특히 multi-query attention과 KV 캐시에 하나의 헤드만 사용하는 경우 4비트 KIVI가 필요하다. (원문: ## 2 Background: Attention Inference-Time Workflow [...] Thus, in Table 3, 4bit KIVI is needed to maintain the accuracy, while 2bit KIVI may have a large accuracy drop in this case.) [웹 <https://arxiv.org/html/2402.02750v2>]
- KIVI는 2비트 양자화의 정확도 하락 문제를 완전히 해결하지 못해 일부 복잡한 추론 작업에서는 정확도 손실이 발생할 수 있다. (원문: For instance, on Llama-2-7B, KIVI-2 shows only a minor accuracy drop (e.g., 13.50 to 12.74 on GSM8K) compared to the severe degradation seen with other 2-bit configurations (e.g., 0.83 for K-T, V-T on GSM8K).) [웹 <https://liner.com/review/kivi-tuningfree-asymmetric-2bit-quantization-for-kv-cache>]

○ confidence: 0.8

- **InfiniGen** — 등급: 경쟁 기술 진영: 중립 / 도입 기업·개발자: 우호 / 투자·미디어: 근거 없음

○ 근거: 경쟁 기술 진영: InfiniGen은 기존 KV 캐시 관리 방법들에 비해 데이터 전송량 감소와 추론 속도 향상에서 우수한 성능을 보이거나, H2O와 같은 다른 접근법은 메모리 사용량 감소와 처리량 측면에서 장점이 있다. 다만 H2O는 정확도 저하가 발생하는 반면 InfiniGen은 정확도 보존에 강점이 있다. [웹

<https://arxiv.org/pdf/2604.05012>] 도입 기업·개발자: InfiniGen은 긴 텍스트 생성에 최적화된 KV 캐시 관리 프레임워크로, 기존 오프로딩 기반 추론 시스템과 시너지 효과를 내며 작동한다. 다양한 대형 언어 모델에서 추론 지연 시간을 크게 단축하고 모델 성능을 유지하며, 배치 크기, 시퀀스 길이, 모델 크기에 대해 이전 솔루션보다 더 나은 확장성을 보였다. [웹 <https://arxiv.org/html/2406.19707v1>] 투자·미디어: 투자자 및 미디어의 직접적인 반응이나 평가 자료가 제공되지 않아 판단 근거가 부족하다. [추론]

○ 긍정:

- InfiniGen은 기존 FlexGen 대비 데이터 전송량 감소로 추론 속도를 크게 향상시켰으며, Ideal 대비 1.52배 느린 반면 다른 방법들은 3.90배에서 18.55배 느리다. [웹 <https://arxiv.org/html/2406.19707v1>]
- InfiniGen은 긴 텍스트 생성에 최적화된 새로운 KV 캐시 관리 프레임워크로, 오프로딩 기반 추론 시스템과 시너지 효과를 내며 작동한다. [웹 <https://arxiv.org/html/2406.19707v1>]
- InfiniGen은 추론 지연 시간을 크게 단축하면서 언어 모델 성능을 유지하였고, 배치 크기, 시퀀스 길이, 모델 크기에 대해 이전 솔루션보다 더 나은 확장성을 보였다. [웹 <https://arxiv.org/html/2406.19707v1>]
- InfiniGen은 중요한 토큰의 KV 캐시를 추측적으로 미리 가져와 GPU로 전송하는 데이터 양을 줄여 KV 캐시 전송 오버헤드를 크게 감소시킨다. [웹 <https://arxiv.org/html/2406.19707v1>]
- InfiniGen은 여러 대표적인 대형 언어 모델에서 기존 KV 캐시 관리 방법 대비 최대 3배의 성능 향상을 보이며, 모델 정확도도 상당히 우수하다. [웹 <https://arxiv.org/html/2406.19707v1>]

○ 부정:

- KV 캐시 크기가 10%보다 작을 때 InfiniGen의 정확도가 눈에 띄게 떨어지는 경우가 있으며, 이는 비트 폭이 충분하지 않은 양자화나 영구적인 KV 캐시 제거 때문일 수 있다. (원문: For relative KV cache sizes larger than 10%, the accuracy with InfiniGen closely) [웹 <https://arxiv.org/html/2406.19707v1>]
- CPU 메모리에서 GPU로 KV 캐시를 전송하는 과정이 LLM 추론에서 새로운 성능 병목 현상이 될 수 있다. (원문: Even so, InfiniGen shows a 1.34×\times speedup over FlexGen, while others) [웹 <https://arxiv.org/html/2406.19707v1>]
- InfiniGen은 CPU-GPU 간 데이터 전송으로 인한 처리량 저하가 있어 고처리량 시나리오에는 제한적일 수 있다. (원문: CONCLUSION We compare three representative KV cache management frameworks: vLLM (memory management), H2O (static sparsification), and InfiniGen (dynamic selection).) [웹 <https://arxiv.org/pdf/2604.05012>]
- InfiniGen은 지연 시간 제약이 완화된 환경에서 정확도 저하를 최소화하는 희소화가 필요한 배포에 적합하지만, CPU-GPU 전송으로 인한 처리량 페널티가 존재한다. (원문: InfiniGen occupies a specialized niche: deployments requiring sparsification with minimal accuracy degradation, where latency constraints are relaxed.) [웹 <https://arxiv.org/pdf/2604.05012>]

○ confidence: 0.85

4.4 도메인 — 스마트폰 온디바이스 (적합 / 조건부 / 부적합 + 포기한 축)

- KIVI — 등급: 적합

- 판정: 적합

- 근거: KIVI는 재학습이나 파인튜닝 없이 plug-and-play 방식으로 동작하며, 추가 하드웨어나 메모리 계층, 대역폭 전제를 요구하지 않는다[논문 p.2]. 따라서 스마트폰 온디바이스 LLM 배포 제약에 부합한다. 정확도 손실과 오버헤드는 판정 조건이 아니지만, INT2 양자화 시 정확도 저하가 있으나 KIVI는 INT2가 아닌 2bit 비대칭 양자화를 사용하여 큰 손실 없이 메모리 절감 효과를 달성한다[논문 p.3][논문 p.8].

- 긍정:

- 재학습·튜닝·보정 데이터가 필요 없으며 plug-and-play 방식으로 적용 가능하다[논문 p.2]
 - 추가 하드웨어, 메모리 계층, 대역폭 전제 조건이 논문에 근거 없음으로 확인되어 대상 기기 자원 전제를 하지 않는다[논문 p.2]

- 부정:

- INT2 양자화 시 정확도에 눈에 띄는 하락이 발생한다[논문 p.3]
 - value cache를 per-channel 양자화하면 정확도가 크게 악화된다[논문 p.3]

- 3축: recall — INT2 양자화 시 정확도 저하가 있으나 KIVI는 2bit 비대칭 양자화로 정확도 손실을 최소화함[논문 p.3] · latency — 논문에 명시된 처리량 증가($2.35\times\sim3.47\times$)는 지연 감소에 긍정적 영향을 미침[논문 p.2] · memory — KV cache 메모리 사용량을 $2.6\times$ 절감하여 메모리 부담을 크게 줄임[논문 p.2]

- confidence: 0.9

- InfiniGen — 등급: 조건부

- 판정: 조건부

- 근거: InfiniGen은 KV 캐시를 GPU 메모리 대신 CPU 메모리에 오프로딩하는 방식을 전제로 하며, 이는 스마트폰 온디바이스 LLM의 메모리 제약과 배포 제약에 부합하지 않는다[논문 p.4][논문 p.6]. 또한, 재학습이나 파인튜닝 없이 적용 가능하다는 근거는 논문에 명확히 제시되어 있지 않다[논문에 근거 없음]. 따라서 대상 기기에 없는 자원(CPU 메모리 오프로딩)을 전제로 하지만, 스마트폰 환경에서 CPU 메모리 활용 및 PCIe 대역폭 관리로 우회 가능성이 있으므로 조건부 적합으로 판단한다[추론].

- 긍정:

- 정확도 손실에 대한 실험 조건과 수치가 논문에 일부 제시되어 있어, 성능 저하를 최소화하는 방법을 확인할 수 있다[논문 p.9][논문 p.12].
 - 추가 하드웨어 없이 재학습·튜닝이 필요 없다는 점은 논문에 근거 없음으로 명확하지 않으나, 오프로딩 방식으로 메모리 부담을 줄이는 시도는 긍정적이다[논문에 근거 없음][논문 p.6].

○ 부정:

- InfiniGen은 CPU 메모리 오프로딩과 PCIe 대역폭 관리를 전제로 하여, 스마트폰 온디바이스 LLM의 메모리 및 배포 제약에 부합하지 않는다[논문 p.4][논문 p.6].
- 재학습·튜닝·보정 데이터가 필요하다는 근거는 없으나, 논문에서 명확히 부정하지 않아 배포 제약 충족 여부가 불확실하다[논문에 근거 없음].
- 데이터 전송 및 연산 오버헤드가 Transformer 실행 시간의 대부분을 차지하여, 추론 지연(latency)이 증가할 가능성이 크다[논문 p.4][논문 p.13].

○ 3축: recall — 정확도 손실 수치는 논문에서 일부 제시되었으나, 전체적인 정보 보존 정도는 불확실하다[논문 p.9][논문 p.12]. · latency — PCIe 대역폭 제한과 데이터 전송 오버헤드로 인해 추론 지연이 크게 증가할 수 있다[논문 p.4][논문 p.13]. · memory — KV 캐시를 CPU 메모리에 오프로딩하여 GPU 메모리 사용량을 줄이는 효과가 있으나, 스마트폰 메모리 환경과는 차이가 있다[논문 p.6].

○ confidence: 0.85

5. 시사점

KIVI는 스마트폰 온디바이스 환경에 적합한 plug-and-play 2bit 양자화 기술로 평가되는 반면, InfiniGen은 CPU 메모리 오프로딩과 PCIe 대역폭 전제를 요구하여 스마트폰 배포 제약에 부합하지 않는 것으로 해석된다. 이러한 차이는 두 기술이 목표로 하는 하드웨어 환경과 메모리 계층 구조에 대한 전제 조건의 차이에서 비롯된다. KIVI는 추가 하드웨어나 대역폭 요구 없이 동작하는 반면, InfiniGen은 CPU와 GPU 간 데이터 전송 병목 가능성을 내포한다는 점에서 도메인 적합성 평가가 엇갈린다[논문 2402.02750 p.2, 2406.19707 p.4, p.6]. 판단에 필요한 추가 확인 항목은 스마트폰 플래시 메모리 대역폭에서의 실제 프리패치 지연 실측이다.

시장 및 채택 관점에서는 KIVI가 중간 수준의 채택과 시장 연결 근거를 갖추고 있으나, InfiniGen은 채택과 시장 연결에 대한 유효한 근거가 부족하여 평가가 엇갈린다. KIVI는 인기 모델 패밀리 적용과 HuggingFace Transformers에 영감을 준 점이 시장 수요와 연결되는 반면, InfiniGen은 구현체 공개에도 불구하고 실제 채택 사례나 벤더 제품 적용 발표가 확인되지 않아 시장 반응을 가늠하기 어렵다[추론]. 판단에 필요한 추가 확인 항목은 InfiniGen의 벤더 제품 적용 사례 및 실사용 데이터다.

기술 성숙도(TRL) 평가에서는 KIVI가 공개 논문과 구현체가 모두 확인되어 TRL 4로 평가되는 반면, InfiniGen은 공개 논문과 구현체만 확인되고 재학습·보정 데이터 및 벤더 제품 적용 발표가 미확인되어 TRL 3으로 평가된다. 이 차이는 기술 검증 단계와 실용화 준비 정도에 대한 해석 차이에서 기인한다[추론]. 판단에 필요한 추가 확인 항목은 InfiniGen의 재학습 또는 보정 데이터 공개 여부다.

이해관계자 관점에서는 KIVI가 경쟁 기술 대비 단순하고 직접적인 2bit 압축 기술로 긍정적 평가를 받는 반면, InfiniGen은 데이터 전송 병목과 정확도 저하 가능성으로 인해 제한적인 평가를 받고 있다. 이는 두 기술이 추구하는 최적화 방향과 구현 복잡성, 정확도 보존 전략의

차이에서 비롯된다[추론]. 판단에 필요한 추가 확인 항목은 InfiniGen의 데이터 전송 병목 현상에 대한 실측 결과다.

두 기술 모두 재학습이나 보정 데이터 없이 기존 모델에 적용 가능하다는 점과 KV 캐시 관리의 중요성을 인지하며 메모리 사용량 및 처리량 개선을 목표로 한다는 점, 그리고 여러 인기 LLM 모델에서 평가되어 GPU 환경에서 효율성 개선을 추구한다는 점에서는 일치한다[논문 2402.02750 p.2, 2406.19707 p.1, p.9].

6. 한계점

1. **공개 정보 기반 추정의 한계** — TRL 4~6 구간은 수율·성능 수치가 비공개라 정보 공백이 가장 크다. 4.1의 등급은 공개 코드·재현·프레임워크 통합 여부만으로 추정한 것이다.
2. **TRL 기준 시점** — arXiv v1과 학회 게재·가이드 표기 시점이 논문마다 다르다(KIVI: v1 2024-02 / ICML 2024-07, InfiniGen: v1 2024-06 / OSDI 2024-07). 기준 시점에 따라 추정이 달라진다 — 발표 시점과 채택 간 시차의 구체 사례다.
3. **사전 가설과 확증편향 방지 조치** — 사전 가설 "온디바이스에서는 SW 압축이 더 적합할 것"을 명시하고 장치 8개(기술별 독립 호출·사실 단위 질의·정확도 임계값 없음·근거 없음 기록·출처 태그 강제·반대 근거 ≥ 2 ·종립성 검증 루프)를 적용했다. 판정 기준(재학습 불필요·전용 HW 불필요)은 배포 용이성에 가중을 두므로 구조적으로 SW 접근에 유리하다 — 도메인의 실제 제약을 반영한 것이지만 기준 선택 자체가 결과에 영향을 준다. Memory·Recall·Latency 3축은 판정이 아닌 해석에만 썼다.
4. **[추론] 태그 비율** — 판단 문장 145건 중 논문·웹 근거 없이 추론에만 의존한 문장 5% (7/145).
5. **검색·생성 품질** — Hit Rate@4 0.8 · MRR@4 0.52 (검색 구성 dual-bm25/ko(dense)+en(sparse), 20문항) · RAGAS Faithfulness 0.936 · ResponseRelevancy 0.838 · ContextPrecision 0.912. 검색 20회 중 "논문에 근거 없음" 4건(KIVI 2건 · InfiniGen 2건). 임베딩 비교는 20문항 기준이라 0.10 차이는 2문항이며, 선정은 수치 우위가 아니라 한국어 질의 요건·컨텍스트 길이에 둔다. 근거 없음이 한 기술에 몰리면 그 기술 판정의 [추론] 비중이 높아진다. 웹 출처는 Tavily가 저자·게시일을 주지 않는 경우가 많아 REFERENCE에 기관명(사이트)과 접근일로 대체했다 — 게시일이 필요한 항목은 사람이 확인해야 한다.
6. **질의 재작성 효과** — 재작성 9건 중 5건이 관련 문서를 찾았다. 효과가 없으면 재작성 단계 제거를 검토한다.

REFERENCE

- Liu, Z., Yuan, J., Jin, H. et al.(2024). KIVI: A Tuning-Free Asymmetric 2bit Quantization for KV Cache. Proceedings of the 41st International Conference on Machine Learning (ICML), PMLR 235. arXiv:2402.02750.
- Lee, W., Lee, J., Seo, J., Sim, J.(2024). InfiniGen: Efficient Generative Inference of Large Language Models with Dynamic KV Cache Management. 18th USENIX Symposium on Operating Systems Design and Implementation (OSDI). arXiv:2406.19707.

- Mamo, O., Kogiou, O., Yi, H. et al.(2026). Comparative Characterization of KV Cache Management Strategies for LLM Inference. arXiv. arXiv:2604.05012.
- jy-yuan(게시일 미상 · 2026-09-22 접근). [ICML 2024] KIVI: A Tuning-Free Asymmetric 2bit github.com, <https://github.com/jy-yuan/KIVI>
- snu-comparch(게시일 미상 · 2026-09-22 접근). GitHub - snu-comparch/InfiniGen: InfiniGen: Efficient Generative Inference of Large Language Models with Dynamic KV Cache Management (OSDI'24) · GitHub. github.com, <https://github.com/snu-comparch/InfiniGen>
- turbo-quant.com(게시일 미상 · 2026-09-22 접근). TurboQuant vs KIVI: KV Cache Quantization Compared | TurboQuant Tools. turbo-quant.com, <https://turbo-quant.com/turboquant-vs-kivi>
- medium.com(게시일 미상 · 2026-09-22 접근). TurboQuant Changes the Economics of Local AI Inference - Medium. medium.com, <https://medium.com/@michael.hannecke/googles-turboquant-changes-the-economics-of-local-ai-inference-acce5839014d>
- liner.com(게시일 미상 · 2026-09-22 접근). KIVI: A Tuning-Free Asymmetric 2bit Quantization for KV Cache [Quick Review]. liner.com, <https://liner.com/review/kivi-tuningfree-asymmetric-2bit-quantization-for-kv-cache>